



Матчинг товаров · Ozon E-CUP 2026

Команда Roma Vazuka · трек 1 · итог на 18.08: локально 0.856, публичный лб 0.4881 — 10 место из 81




Задача

Кандидатные пары ДАНЫ: только классификация «та же карточка или нет». Retrieval не нужен. Вход — текст: имя, категория, атрибуты. Картинок нет.



Данные

Ручная разметка 366K пар (метки 0/1) + LLM-разметка 11.2M пар (мягкие 0...1). Вселенные товаров не пересекаются — LLM-пары леик-фри для претрена.



Как выглядит карточка

Название свободной формы + свёрнутый JSON атрибутов. Ключи и стиль у продавцов разные — прямое сравнение полей почти невозможно.

шлепанцы adissage f35579 adidas синий 46 eu · [Обувь]

артикул производителя: 0000200858654-46; бренд: adidas;

код товара: 100052528706; материал верха: резина, пластик;

модель: adissage f35579; пол: унисекс; размер: 45 46 eu;

размер ru: 45; размер производителя: 46 eu; серия: 888 ...

Пара-позитив: размер НЕ важен

Vans: размер 44,5 RU против EU 38.5 — всё равно матч. Конвенция: «тот же товар» = модель + цвет, размерная сетка игнорируется.

A · vans кеды, 44,5 ru, белый/чёрный

артикул: vd3hy28 11

бренд: vans

размер: 44,5 ru

цвет: черный, белый

B · кроссовки vans

бренд: vans

размер производителя: eu 38.5

российский размер: 37,5

цвет: черно-белый

target = 1

Пара-негатив: цвет решает

Fre gamo, обе — сандалии той же марки. Чёрные против жёлтых → разные товары. Негативы в фэшне — «почти тот же» товар.

A · сандалии fre gamo

бренд: fre gamo

название цвета: черный

размер производителя: 43

пол: мужской

B · fre gamo / сандалии

российский размер: 41

цвет: желтый


комплектация: 1 пара

страна: китай

target = 0


Категории неравны

Позитив-рейт от 11.8% (Одежда) до 56% (Детские товары): фэшн намеренно набит трудными негативами «почти тот же товар».




Замороженная валидация

4 фолда по компонентам связности графа пар: товар никогда не в двух фолдах. Таргеты запинены SHA256 — фолды не двигаются под модель.




Метрика: расшифровали total_prauc

API вернул per-category скоры: среднее 20 категорий сходится с total до 4 знака. Метрика — МАКРО по категориям, каждая весит 1/20.




Путь сора: 0.638 → 0.856

30 скоримых итераций на замороженных фолдах. Каждый шаг ниже — отдельный слайд с решением и заплаченной ценой.




Бейзлайны и классика

Имена почти не разделяют классы: tfidf 0.33. Дерево на 21 дешёвой фиче — 0.638. KNRM с навес-инициализацией — 0.53.




Решение 1: масштаб энкодера

Кросс-энкодер. rubert-tiny2 хуже lgbm (0.565). rubert-base сразу +0.15 к лучшему бейзлайну. Масштаб — самый большой одиночный рычаг: +0.21.




Решение 2: претрен на 11.2М LLM-пар

ВСЕ на мягких метках чужой вселенной товаров (пересечение с ручной = 0), потом FT на ручных. +0.038.
Второй проход претрена — ещё +0.002.




Решение 3: длина контекста

Самый надёжный рычаг: каждый шаг 128→160→224→288→384 платил +0.002...0.006. Атрибуты до 800 символов, обрезаются только 9%.




Решение 4: разные архитектуры

e5-base и mdeberta-v3 слабее ruBERT-base поодиночке, но кросс-архитектурный ансамбль даёт +0.006–0.008 — а same-arch бэггинг лишь +0.0005.




Решение 5: ансамбль + стек

7 членов (3 архитектуры × длины) → ранк-среднее 0.8541. LGBM-стек с 21 фичей — 0.8543. Их ранк-микс — 0.8555.




Решение 6: zero-shot LLM свип

Гипотеза Романа: LLM-ризонинг для пар. P(«1») первого токена, промпт с атрибутами. Лучшие — gemma-4-E4B и Qwen3.5-4B ≈ 0.67 .




Решение 7: LLM в стек

$\text{rank}(\text{CE}) \cdot 0.94 + \text{rank}(\text{LLM}) \cdot 0.06 = 0.85638$. Дельта +0.0009 — маленькая, но плюс на всех 4 фолдах. Новый топ-1 команды.




Проверенные гипотезы

Каждая гипотеза — измерение на замороженных фолдах. Критерий значимости: одинаковый знак дельты на всех четырёх фолдах.




Гипотеза: KNRM докинет стеку — НЕТ

Воспроизвели knrm_name_v2 (OOF 0.531 = 0.530 у Романа). Лучший вес 0.01: +0.00006, знак гуляет по фолдам. Кernels имён SE уже выучил.



Гипотеза: учиться на исправленных метках — НЕТ

Флипнули 1336 пар, где CE и LLM уверенно против метки. -0.0014 на всех фолдах; на парах без флагов ≈ 0 .
Нужна ручная доразметка.



Посылка ОДС = код-контейнер

Лимит 20 минут на весь тест (~366K пар). Наши посылки: fp16, батчи по длине, авто-деградация max_len и тайм-гард на вторую модель.

zip ~0.9 ГБ

run.py
models/ (fp16)
metadata.json

модель 1

rubase len192
~8 мин

тайм-гард


осталось время?
да → модель 2
нет → пишем

вывод

id1,id2,predict
< 20 мин


Четыре посылки первого дня

Фулл-бленд 3 архитектур показал 0.4902, но не влез в лимит (error). Засчитан пара rubase+mdeb: 0.4881 — 10 место из 81.




Локальной валидации можно верить

Шкалы разные ($0.85 \leftrightarrow 0.48$), но порядок решений сохраняется: бленд лучше стендалона на $+0.006$ и локально, и на лб.




Главная находка: фэшн лежит на тесте

Одежда 0.095 и Обувь 0.099 на тесте против 0.60/0.58 локально. Именно фэшн топит макро-метрику — вес каждой категории 1/20.




Почему фэшн трудный: имена — анти-сигнал

В Обувь у негативов перекрытие имён ВЫШЕ, чем у позитивов (0.337 против 0.308). В Электронике наоборот: имя решает (+0.107).



Что реально разделяет пары в фэшне

Совпадение цвета: 64% у позитивов против 40% у негативов. Артикул почти безошибочен (37% против 3%), но есть лишь у 5–37% пар.



И разметка местами битая

Одинаковый артикул lbjx010013, те же габариты и цвет — метка 0. Такие дубли-с-меткой-0 мы ловим согласием двух независимых моделей.

А · сумка baseus easyjourney dark grey

артикул: lbjx010013

высота: 11.5 см · ширина: 17.5 см

цвет товара: серый

В · сумка baseus easyjourney серая

артикул: lbjx010013


высота: 11.5 см · ширина: 17.5 см

цвет товара: серый

target = 0 ?!


1336 пар на доразметку

CE-ансамбль и zero-shot LLM уверенно согласны ПРОТИВ метки: 993 «на деле матч» + 343 «на деле разные».
CSV и паркет предиктов — в репе.



Где теряем total_prauc

Разрыв (локальный — тест) на вес 1/20: фэшн-категории дают половину всей потери метрики. Обувь и Одежда — по 0.025 total каждая.



Направление 1: конвенция матча

Модель должна выучить «модель+цвет, размер игнорируй». В работе: приоритет атрибутов + символьные сравнения цвета/артикула прямо в тексте пары.

Новый текст пары (эксперимент prio)


бренд → модель/артикул → цвет → материал → ... (вместо алфавита)

фэшн: размерные атрибуты выброшены

@@ сравнение: цвет=различен; артикул=неизвестно


Направление 2: дистилляция ансамбля

Ансамбль 0.856 не влезает в 20 минут. Студент rubert-base учится на 0.7·стек + 0.3·метка — переносим ансамбль в одну модель контейнера.



Направление 3: чистые метки

Авто-флип не сработал (-0.0014) — исправления должен подтвердить человек. 1336 пар ждут ручной доразметки, приоритет — фэшн и Галантерея.



План до дедлайна 30.08

Сегодня: спец-фэшн посылка + дистилляция. Дальше: ручная доразметка, len384 в контейнер через деградацию, финальный отбор 2 посылок.

